PORTFOLIO

K I M - U K Y O U N G

데이터 분석 역량을 기르기 위해 다양한 도메인의 데이터를 다루며,
문제 정의부터 분석 결과 해석까지의 과정을 정리하였습니다.

contact

phone : 010 2890 2501 | mail : ukyoung_k@naver.com

KIM-UKYOUNG

CONTENTS

프로젝트 1 01

서울시 아파트 실거래가에 영향을 미치는
환경 요인 분석

프로젝트 2 02

Natural Language Processing
with Disaster Tweets

프로젝트 3 03

딥러닝 기반 중고
스마트폰 거래 도움 서비스

서울시 아파트 실거래가에 영향을 미치는 환경 요인 분석

자연 인접 대단지 vs 상권 인접 중소단지, 더 비싼 곳은?

Background | 프로젝트 배경

부동산 시장에서 다양한 '입지 프리미엄'들이 홍보되고 있지만,
그 '입지'가 실제 거래 가격에 어떤 방식으로 작용하는지는 명확히 검증된 바가 적다.

이에 서울시 아파트 실거래 데이터를 기반으로 자연 접근성, 상권 접근성, 단지 규모가 거래 금액에 미치는 실질적 영향을 검증하고자 했다.

Objective | 분석 목표

- 환경 요인(자연 인접+대단지 vs 상권 인접+중소단지)에 따른 거래 금액 차이 검증
- 대시보드를 제작하여 분석 결과를 시각적으로 이해하기 쉽게 전달
- 부동산 정책 또는 거래 의사 결정에 참고할 수 있는 인사이트 도출

Approach | 분석 접근 방식

- 국토교통부 실거래 데이터와 서울시 대규모 점포, 주요 공원, 단지 규모 데이터를 결합하여 환경 변수 생성
- 카카오맵 api를 활용한 거리 계산으로 자연, 상권 접근성 정의
- 단측 t-test 로 집단 간 평균 거래 금액 차이 검증
- Tableau 대시보드로 거래 분포를 시각화하고, 그룹별 가격 패턴 비교

Expected Insights | 예상 인사이트

- 자연 또는 상권 접근성과 단지 규모가 아파트 가격에 실질적인 영향을 줄 것으로 예상한다.
- 상권 접근성이 높더라도, 자연 인접성과 단지 규모가 더 큰 프리미엄 요인으로 작용할 가능성을 검증하고자 한다.
- 본 분석을 통해 주거지 선택에 환경 요인이 미치는 영향을 파악할 수 있을 것으로 기대한다.

(Period: 2025. 06. 24~ 2025. 07. 09 / Tool: SQL, Python, Tableau)

서울시 아파트 실거래가에 영향을 미치는 환경 요인 분석

01

프로젝트 수행 절차

데이터 수집

1. 환경 요인 정의 및 필요 데이터 탐색
2. 데이터 수집

데이터 전처리

1. 실거래 데이터 전처리 (SQL)
2. 이상치 확인 및 처리 (Python)

데이터 변환

1. 카카오맵 api를 활용한 위경도 변환
2. 환경 요인 변수 정의 및 생성

가설 검증

1. t-test

시각화 및 결론 도출

1. Tableau 활용한 시각화
2. 두 집단 간 아파트 실거래가에 대한 결론 도출

서울시 아파트 실거래가에 영향을 미치는 환경 요인 분석

01

데이터 전처리 & 변환 (SQL + Python)

1. 아파트 매매 실거래 데이터 전처리 (SQL)

- 최근 3년(2022년~2024년) 간 서울시 아파트(매매) 실거래 데이터 대상으로 테이블 생성
- 거래 해제 건을 제거하고, 가격 단위 표준화를 위해 파생 컬럼(전용 면적당 금액)을 추가
- 지역별 분석을 위해 주소에서 자치구만 추출하여 파생 컬럼 추가

2. 데이터 분포 확인, 이상치 처리 (Python)

- 히스토그램을 통해 전용면적당 금액의 분포 확인
- 오른쪽으로 꼬리가 긴 비정규형 분포: 로그 변환하여 분포 왜곡 완화 및 정규성 확보
- 박스플롯을 통한 전용면적당 금액 이상치 확인: 상·하단에 이상치 다수 분포
- 시장의 전반적인 경향 확인을 위해 상·하단 극단 일부만 제외 (1%~99% 분위수 사용)

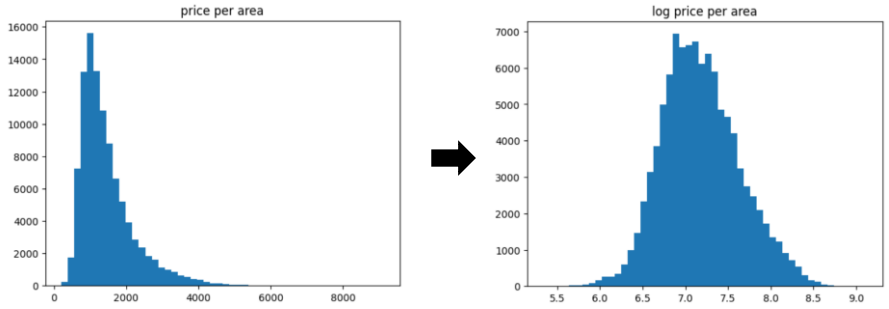

3. 데이터 변환 (Python)

1) 주소 위경도 변환

- 아파트와 주변 시설 간의 거리 계산을 위해 주소를 위도, 경도 값으로 변환
- 카카오맵 api를 활용하여 아파트와 주변 시설의 주소 변환

2) 환경 요인 변수 정의 및 생성

- 대립 그룹을 설정하기 위해서 각 변수를 정의하고, 파생 컬럼 생성
- 자연 인접(숲세권): 아파트 단지 1km 이내 산 또는 공원이 1개 이상 위치
- 상권 인접(몰세권): 아파트 단지 1km 이내 백화점, 대형마트, 복합쇼핑몰, 쇼핑센터 중 1개 이상 위치
- 단지 규모: 총 세대수 1,000세대 이상은 '대단지', 그 미만은 '중소단지'로 표기

서울시 아파트 실거래가에 영향을 미치는 환경 요인 분석

01

가설 검정: 독립표본 t-test

- **가설 검정 배경**
- 서울시 아파트 거래금액의 로그 변환 후 분포가 정규성 가정을 충족
  → 로그 변환된 거래금액으로 정규성 확보 후, 단측 Welch t-test 수행
- 검정 목적: '자연+대단지' 집단의 평균 거래금액이 '상권+중소단지' 그룹보다 유의미하게 높은가를 확인

- **가설 설정**
- H0 (귀무가설): 두 그룹 간 평균 거래금액(로그 기준)에 유의미한 차이가 없다.
- H1 (대립가설): 자연+대단지 그룹의 평균 거래금액이 상권+중소단지 그룹보다 높다.

- **정규성 확인**
- 두 그룹의 거래금액 분포 확인 (히스토그램)

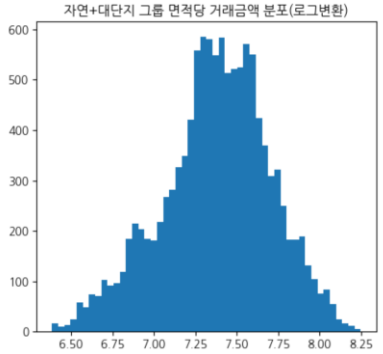

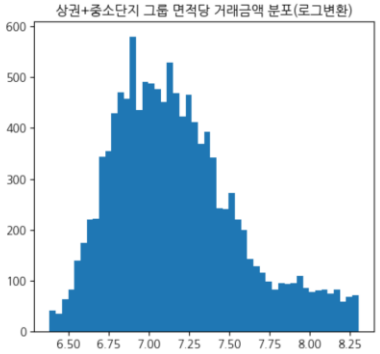

- **검정 결과**

검정항목	결과	해석
Levene's Test	$p < 0.05$	등분산성 불충족 → Welch t-test 적용 (equal_var=False)
t-test (단측)	$p < 0.05$	귀무가설 기각 → 자연+대단지 그룹의 평균이 유의미하게 큼

- **결과 해석**
- 로그 변환된 거래금액 기준, 자연+대단지 그룹의 평균 거래금액이 상권+중소단지 그룹보다 통계적으로 유의하게 높음 ($p < 0.05$)
- 로그 스케일 차이를 지수화한 결과, 자연+대단지 아파트의 평균 거래금액은 상권+중소단지 대비 약 23% 더 높은 수준으로 해석됨
- 자연 접근성과 단지 규모가 실제 시장에서 프리미엄 요인으로 작용함을 확인

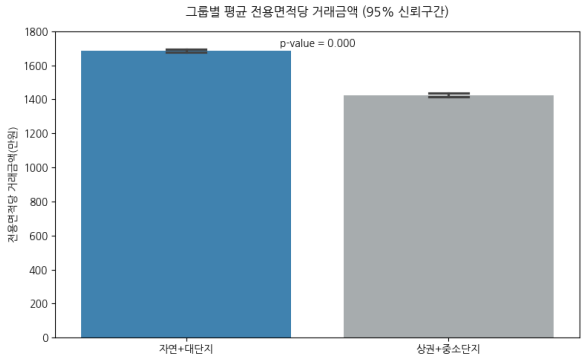

서울시 아파트 실거래가에 영향을 미치는 환경 요인 분석

01

시각화

- **시각화 개요**
  - Tableau를 활용하여 서울의 아파트 거래 개요와 그룹별, 자치구별 거래 패턴을 직관적으로 보여주는 대시보드 작성
  - 필터 기능을 활용하여 자치구별로 거래 개요 확인 가능
- **주요 인사이트**
  - 지난 3년 간 자연 인접+대단지 아파트의 평균 거래금액이 일관되게 높게 형성되고 있음을 확인
  - 다만 모든 자치구가 동일한 경향을 보이진 않으며, 일부 자치구에서는 상권 인접+중소단지의 거래 금액이 더 높게 나타나는 것을 확인

아파트 밸런스 게임 : 자연+대단지 VS 상권+중소단지

(2022년-2024년 서울시 아파트(매매) 실거래 데이터)

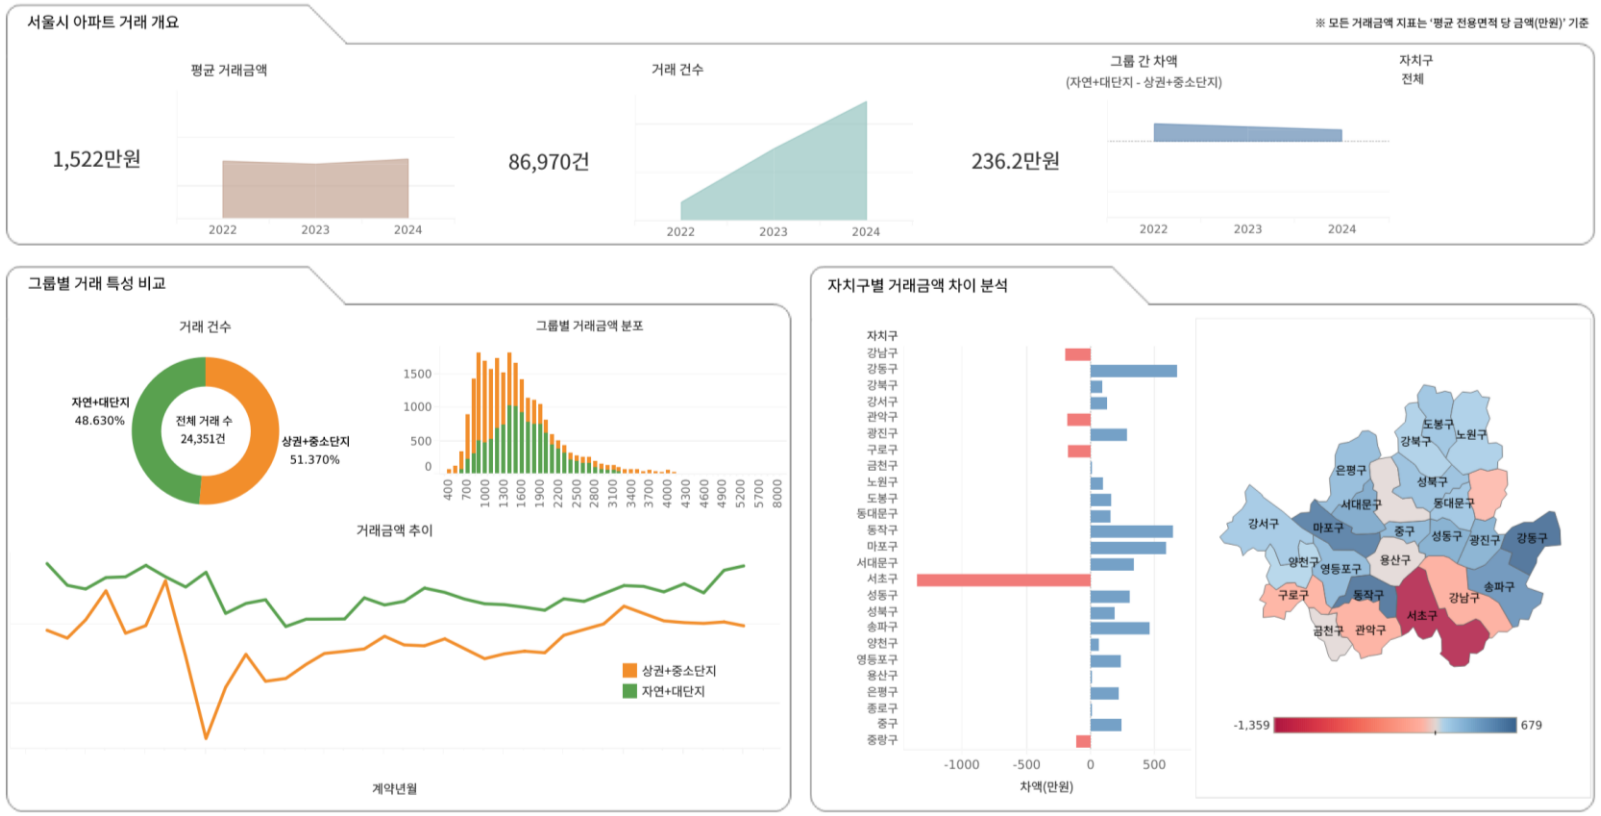

Tableau Public: https://public.tableau.com/app/profile/.70596571/viz/_17595049947020/1

서울시 아파트 실거래가에 영향을 미치는 환경 요인 분석

01

결론 및 시사점

Summary | 분석 요약

데이터 수집 및 전처리	2022년~2024년 서울시 아파트(매매) 실거래 데이터와 환경 요인 관련 공공데이터 수집, 가격 표준화 및 로그 변환으로 정규성 확보
가설 검정	단측 Welch t-test를 통해 자연+대단지 그룹이 상권+중소단지보다 평균 거래금액이 유의미하게 높음 확인
시각화	Tableau를 통해 거래 개요, 그룹 및 자치구별 차이를 시각적으로 검증

Key Finding | 주요 결과

- p-value < 0.05로 자연+대단지 그룹의 평균 거래금액이 유의미하게 높음
- 실제 거래 금액 기준으로 약 1.23배 높은 수준으로 확인됨
- 자연 접근성과 1,000세대 이상의 대단지가 실제 시장에서 프리미엄 요인으로 작용함

Implication | 시사점

1. **정책적 측면**
   환경 요인 중심의 주거 정책, 도시 계획 수립에 근거 데이터 제공
2. **비즈니스 측면**
   부동산 마케팅, 입지 분석, 신규 개발 사업의 입지 프리미엄 예측 모델 설계에 응용 가능
3. **분석 확장 가능성**
   교통, 학군, 건축 연도 등 추가 변수를 결합한 다변량 회귀 분석 또는 ML 모델로 확장 시 가격 결정 요인 모델링 또는 부동산 가치 예측 자동화로의 발전 가능

본 분석을 통해 자연 접근성과 단지 규모가 서울시 아파트 실거래 가격에 실질적 영향을 미치는 요인임을 확인하였다.
단순 입지 요인을 넘어 환경과 규모 중심의 프리미엄 패턴을 데이터로 검증하였으며, 향후 주거 입지 평가 및 도시 계획 수립의 근거로 활용될 가능성을 보여준다.

Natural Language Processing with Disaster Tweets

02

Kaggle Competition

Background | 프로젝트 배경

SNS, 특히 트위터(X)는 재난 발생 시 실시간 정보가 가장 빠르게 공유되는 채널로, 재난 구호 단체나 통신사 등에서 이를 체계적으로 모니터링하는데 관심을 보이고 있다.

그러나 재난 관련 단어를 포함하더라도 실제 재난과 무관한 게시물이 많아 단순 키워드 필터링만으로는 정확한 재난 탐지가 어렵다.

이에 Kaggle의 Disaster Tweets 데이터를 기반으로 실제 재난 상황과 관련된 게시물을 자동으로 분류하는 모델을 개발하고자 했다.

Objective | 분석 목표

- 트위터 게시물의 문맥을 분석해 실제 재난 관련 여부를 분류하는 모델 개발
- 텍스트 벡터화 기법 및 머신러닝 모델을 비교하여 최적의 분류 성능 확보
- Kaggle Competition 환경에서 F1 score 기준으로 Submission score 향상

Approach | 분석 접근 방식

- Kaggle의 Disaster Tweets 데이터셋(키워드, 위치정보, 게시물) 기반으로 데이터 전처리 수행
- 텍스트 벡터화: BERT 임베딩, TF-IDF, 타겟 인코딩 등 다양한 피처링 방식 적용
- 모델링: 로지스틱 회귀, XGBoost 기반 분류 모델 개발 및 하이퍼파라미터 튜닝 수행
- 모델 평가: train-validation gap을 통해 과적합 여부를 점검, F1 score를 통해 모델 성능 비교

Expected Insights | 예상 인사이트

- 단순 키워드 기반보다 문맥 정보를 포함하는 임베딩이 실제 재난 맥락을 더 정밀하게 분류할 수 있을 것으로 기대한다.
- 추가 정보로 주어진 키워드와 위치 정보가 분류 성능에 긍정적인 영향을 줄 것으로 예상한다.
- 본 분석을 통해 자연어 기반 재난 인식 모델의 일반화 가능성 및 한계를 탐색하고자 한다.

(Period: 2025.06.24 ~ 2025.07.09 / Tool: Python)

Natural Language Processing with Disaster Tweets

02

프로젝트 수행 절차

EDA

1. train, test 데이터 및 칼럼 확인
2. train 데이터의 target 비율 확인
3. train, test 데이터의 결측치 확인

데이터 전처리

keyword, location 변수 전처리

- 결측치 처리
- 인코딩 변환

텍스트 임베딩

text 변수 임베딩 모델 선정 및 변환

모델 선정 및 고도화

1. 로지스틱 회귀 모델
2. XGBoost
3. Feature Engineering

- keyword, location 변수 전처리 방식 변경

Natural Language Processing with Disaster Tweets

데이터 전처리

1. 결측치 처리
- keyword, location: 텍스트 기반의 범주형 변수
- keyword 결측: train 61건, test 26건
- location 결측: train 2,533건, test 1,105건
- 두 변수 모두 결측치가 많아 'unknown' 범주로 단일 대체

2. 변수 인코딩
- keyword, location의 고유 값의 수가 매우 많아 원-핫 인코딩은 부적합
- Target encoding 방식을 적용, 각 고유값 별 평균 target 값을 수치로 변환
- 단순 인코딩보다 실제 재난과의 연관성을 더 정량적으로 반영하고자 함

3. 데이터 분할
- train(56%) / validation(14%) / test(30%) split
- train-validation gap 기반 일반화 성능 검증과 모델 평가에 활용

텍스트 임베딩

1. BERT 임베딩 모델 선택
- TF-IDF 방식보다 문맥을 반영할 수 있는 BERT 임베딩 방식이 성능 향상에 효과적일 것으로 기대
- text 변수는 실제 트위터(X) 게시물 데이터로 이루어짐
- 다수의 영어 트윗으로 사전학습 되어 줄임말, 해시태그, 특수문자 등 트위터 특성에 최적화된 'BERTweet' 모델 선택

2. 임베딩 방식
- 입력된 문장을 토크나이징하여 BERTweet 모델에 입력
- 출력된 마지막 히든 스테이트 평균값을 사용해 최종 768차원 임베딩 벡터 생성
- 결과값을 머신러닝 모델의 입력값으로 사용

Natural Language Processing with Disaster Tweets

모델 선정 및 고도화

1. 로지스틱 회귀 모델

- BERTweet 임베딩의 기본 분류 성능을 빠르게 확인하기 위해 로지스틱 회귀 모델 사용
- 결측치가 많은 keyword, location 변수를 제외한 모델과 포함한 모델의 성능 비교

(A) text 변수 단독 학습 모델 평가 결과

```
0.049 => 과적합 아님
f1 score = 0.785
              precision    recall  f1-score   support

           0       0.83      0.86      0.85      1318
           1       0.81      0.77      0.79       966

    accuracy                           0.82      2284
   macro avg       0.82      0.82      0.82      2284
weighted avg       0.82      0.82      0.82      2284
```

(B) text, keyword, location 학습 모델 평가 결과

```
0.135 => 과적합
f1 score = 0.755
              precision    recall  f1-score   support

           0       0.81      0.84      0.83      1318
           1       0.77      0.74      0.76       966

    accuracy                           0.80      2284
   macro avg       0.79      0.79      0.79      2284
weighted avg       0.80      0.80      0.80      2284
```

→ keyword와 location 변수를 활용한 경우, text 변수 단독 학습 대비 모델 성능이 하락
→ 두 변수의 정보값이 낮아 문맥 기반 임베딩과 충돌하여 오히려 노이즈로 작용한 것으로 해석
→ 단순 타겟 인코딩 방식 보다 더 정교한 방식으로 변환할 필요가 있음을 확인

2. XGBoost

- 비선형적 패턴을 포착하기 위해 트리 기반 모델로 확장
- 로지스틱 회귀 모델에서 더 좋은 성능을 보였던 text 임베딩만 단독 학습
- 기본 모델과 하이퍼파라미터 튜닝 모델의 성능 비교
- 튜닝: GridSearch(learning_rate, max_depth, min_child_weight, n_estimators)

(A) 기본 모델 평가 결과

```
0.199 => 과적합
f1 score = 0.779
              precision    recall  f1-score   support

           0       0.83      0.87      0.85      1318
           1       0.81      0.75      0.78       966

    accuracy                           0.82      2284
   macro avg       0.82      0.81      0.81      2284
weighted avg       0.82      0.82      0.82      2284
```

(B) 하이퍼파라미터 튜닝 모델 평가 결과

```
0.185 => 과적합
f1 score = 0.785
              precision    recall  f1-score   support

           0       0.83      0.88      0.85      1318
           1       0.82      0.75      0.78       966

    accuracy                           0.82      2284
   macro avg       0.82      0.82      0.82      2284
weighted avg       0.82      0.82      0.82      2284
```

→ 기본 모델은 로지스틱 회귀 모델에 비해 성능이 소폭 하락함. 하이퍼파라미터 튜닝을 통해 동일 수준까지 향상
→ 트리 모델의 특성 상 과적합 경향을 보임. 이를 완화하기 위해 추가적인 하이퍼파라미터 조정이 필요할 것으로 보임
→ keyword, location 변수 추가는 XGBoost에서도 성능 하락 → target encoding 방식 미채택

Natural Language Processing with Disaster Tweets

모델 선정 및 고도화

3. Feature Engineering & 최종 모델 선정

- keyword, location 변수를 적절하게 활용할 경우 text 변수 단독 사용 보다 모델 성능이 개선될 것으로 예상
- 그리드 서치 결과를 바탕으로 과적합 억제 파라미터를 추가하여 XGBoost 모델 생성

(A) BERTweet 모델 임베딩 + PCA 차원 축소

- 타겟 인코딩에 비해 단어/문맥의 의미를 보존하여 더 많은 정보를 학습 가능
- 3개의 변수 각각 임베딩: 차원이 불필요하게 커지는 문제 발생
  → keyword와 location 변수는 누적 분산 비율 90% 기준으로 PCA 차원 축소 진행

- BERTweet 임베딩 모델 평가 결과

```
0.188 => 과적합
f1 score = 0.795
              precision    recall  f1-score   support

           0       0.83      0.89      0.86      1318
           1       0.84      0.76      0.79       966

    accuracy                           0.83      2284
   macro avg       0.83      0.82      0.83      2284
weighted avg       0.83      0.83      0.83      2284
```

→ text 임베딩 단독 학습 모델보다 성능 향상됨
→ 단순 인코딩 변환보다 텍스트 의미를 내포하는 임베딩 방식이 모델 성능 향상에 효과적

(B) TF-IDF 벡터화 + SVD 차원 축소

- keyword와 location 변수 자체는 게시물 내용과 직접적인 연관이 없어 BERTweet 임베딩이 성능 향상에 큰 효과를 주지 못할 것으로 추정
- keyword 변수: 단일 단어로 구성 → 타겟 인코딩
- location 변수: TF-IDF 변환 후 SVD 차원 축소 진행

- TF-IDF 변환 모델 평가 결과

```
0.189 => 과적합
f1 score = 0.799
              precision    recall  f1-score   support

           0       0.84      0.89      0.86      1318
           1       0.83      0.77      0.80       966

    accuracy                           0.84      2284
   macro avg       0.84      0.83      0.83      2284
weighted avg       0.84      0.84      0.84      2284
```

→ 보조 변수(keyword, location)를 활용한 모델 중 가장 높은 F1 score를 달성, 최종 모델로 선정
→ 각 변수의 특징에 알맞은 인코딩/벡터화 방식을 적용하는 것이 모델 성능 향상에 효과적임을 확인

Natural Language Processing with Disaster Tweets

02

결론 및 시사점

Summary | 분석 요약

데이터 전처리	keyword, location 결측치 처리, target encoding 적용
텍스트 임베딩	데이터의 특성에 맞는 BERTweet 모델 선정, 임베딩 적용
모델링	Logistic Regression → XGBoost 기본 모델 → XGBoost 하이퍼파라미터 튜닝 순으로 성능 개선. Train-validation gap과 F1 score 기준 성능 평가
피처 엔지니어링	Keyword와 location 변수 활용을 위해 벡터화 방식 비교

Key Finding | 주요 결과

- keyword, location 변수 추가 시 모델 성능 하락: 해당 변수의 정보량이 적어 노이즈로 작용
- XGBoost 기본 모델은 로지스틱 회귀 모델보다 성능이 낮았으나, 하이퍼파라미터 튜닝을 통해 동일 수준까지 성능 향상. 하지만 과적합 경향 보임
- 결측치 비율이 높았던 location 변수는 단순 target encoding 보다 TF-IDF 방식이 더 효과적
- Kaggle Submission Score: 0.82286

Implication | 시사점

1. **모델링**
   텍스트 기반 NLP 분류에서는 복잡한 모델보다 적절한 파라미터 튜닝이 더 중요함을 확인
   보조 변수(keyword, location)는 단독 정보량이 적어 문맥 기반 임베딩 중심 모델 구조가 효율적
2. **데이터 처리**
   keyword, location 변수에 target encoding 방식을 적용했을 때는 성능이 하락했지만, 벡터화 방식을 적용하니 성능 향상에 기여함. 전처리 적합성의 중요성을 확인
3. **활용 가능성**
   재난 관련 문맥을 효율적으로 학습하는 모델은 재난 감지 시스템, 공공 안전 알림 서비스 등의 자동화 기반이 될 수 있음

텍스트 맥락을 반영하는 임베딩 방식이 재난 탐지 정확도에 크게 기여하였으며, 보조 변수의 경우 적합한 전처리 방식을 적용할 때만 분류 정확도에 긍정적으로 작용했다.
추후 머신러닝 모델 다양화와 BERT 모델 파인 튜닝을 통해 추가적인 성능 향상을 기대해볼 수 있다.

딥러닝 기반 중고 스마트폰 거래 도움 서비스

03

시계열 분석을 통한 중고 스마트폰 미래 가격 예측

Background | 프로젝트 배경

중고 스마트폰 시장은 지속적으로 성장하여, 2023년 기준 778만대의 거래 규모를 이루고 있다.

하지만 스마트폰의 특성 상 모델, 외관 상태, 성능 등 변수가 많아 가격 편차가 크고 주관적이기 때문에 적정 시세 파악이 어렵다는 문제가 지속되고 있다.

이미지 기반 자동 상태 판정과 과거 거래 데이터를 활용한 가격 예측을 통해 소비자와 판매자 모두 신뢰할 수 있는 거래 환경을 제공하는 서비스를 개발하고자 한다.

Objective | 분석 목표

- 스마트폰 외관 이미지를 활용해 손상 상태(상/중/하) 분류 모델 개발
- 실시간 거래 데이터를 활용한 미래 가격 예측 모델 개발
- 이용자가 사진을 업로드하면 외관 상태와 예측 가격을 안내하는 서비스 프로토타입 구축

Data | 활용 데이터

- 스마트폰 실물 이미지 약 3만 장 (웹 크롤링, 자체 수집)
- 중고 스마트폰 거래 설문조사 응답 결과 (119건, 자체 수집)
- 중고폰 안심 거래 사업자(폰가비) 실시간 중고 스마트폰 거래 데이터 (25. 8. 8 기준)

Approach | 분석 접근 방식

- 이미지 전처리: resize, augmentation
- 외관 상태 판정: CNN 기반 손상 상태 분류 모델 개발
- 가격 예측: 시계열 기반 TCN(Temporal Convolutional Network) 모델 개발
- 모델링, 예측 지표를 기반으로 서비스 데모 페이지 UX 설계
- 데이터 파이프라인 설계 및 자동화 프로토타입 구현

Expected Insights | 예상 인사이트

- 이미지 기반 자동 상태 분류 모델이 판매자의 주관보다 일관된 판단을 제공할 것으로 기대한다.
- 특정 모델, 용량, 상태 조합 별로 가격 패턴을 학습하여 미래 시점의 가격을 예측하고자 한다.
- 실제 서비스 적용 시, 허위 또는 과대 평가 매물의 필터링이 가능해질 것으로 기대한다.
- 향후 B2B(중고폰 매입 업체) 및 C2C 플랫폼(중고나라, 당근마켓 등)에서 활용 가능한 자동화 기능으로의 확장 가능성이 있다.

(Period: 2025.07.09 ~ 2025.08.19 / Tool: Python, Tensorflow, Postgre SQL)

딥러닝 기반 중고 스마트폰 거래 도움 서비스

프로젝트 수행 절차

데이터 수집

1. 중고 스마트폰 거래 경험 설문조사
2. 스마트폰 이미지 크롤링
3. 중고 스마트폰 거래 데이터 수집
4. 스마트폰 사양 관련 데이터 수집

데이터 전처리

1. 스마트폰 이미지 증강
2. 스마트폰 품질 라벨 분류
3. ERD 설계
4. 중고 스마트폰 거래 데이터 전처리

모델 학습 및 평가

1. 스마트폰 이미지 분류 모델 개발
2. 중고 스마트폰 가격 예측 모델 개발
3. 스마트폰 판매 예시 문구 생성 모델

서비스 구현

1. 스마트폰 사용 유형 테스트 설계
2. 웹사이트 구축
3. AI 홍보 영상 제작

(수행 업무)

스마트폰 이미지 크롤링
- selenium을 활용하여 검색 키워드 기반 크롤링과 구글 이미지 렌즈 기반 크롤링 진행

중고 스마트폰 가격 예측 모델 개발
- 중고 스마트폰 거래 데이터 탐색
- 시계열 분석 모델 선정
- 데이터 전처리
- 모델 학습 및 평가
- 가격 예측 그래프 시각화

스마트폰 사용 유형 테스트 설계
- 스마트폰 사용자 유형 정의
- 유형 테스트 문항 설계
- 테스트 결과 화면 작성

딥러닝 기반 중고 스마트폰 거래 도움 서비스

- 시계열 분석을 통한 중고 스마트폰 미래 가격 예측

03

중고 스마트폰 거래 데이터 탐색

1. 데이터 탐색 및 주요 변수

- 데이터 출처: 중고폰 안심거래 사업자 '폰가비'의 실시간 중고 거래 시세 크롤링 (약 2만건)
- 전처리: 스마트 워치, 태블릿 등 스마트폰이 아닌 데이터 삭제, 이상치 처리, 인덱스 생성
- 주요 변수

rp_idx	거래 인덱스
rp_pm_idx	핸드폰 기종 인덱스
rp_grde	등급 (A ~ C)
rp_model	핸드폰 기종 (갤럭시 S25, 아이폰 16 등)
rp_capacity	용량 (64GB, 128GB 등)
rp_price	거래 가격

2. 데이터 특징

- 하나의 거래 데이터셋에 모든 기종, 용량, 등급의 데이터가 혼재되어 있음
- 거래 순서는 있지만, 정확한 거래 일자 데이터가 부재
- 동일 기종 내에서도 용량과 등급에 따라 다양한 조합 존재

3. 거래 패턴 확인

- 동일 기종/용량/등급 조합의 거래 금액 변동 패턴 확인
- 모델 예시: 아이폰13/128GB/A등급, 갤럭시 S23/256GB/A등급
- 전체적인 중심 가격은 있지만 산발적으로 큰 낙폭이 존재
- 가격의 추세성이나 주기성은 눈에 띄지 않음

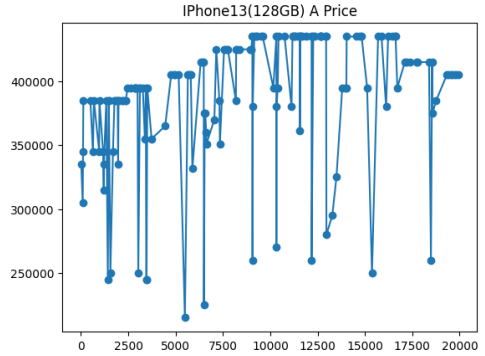

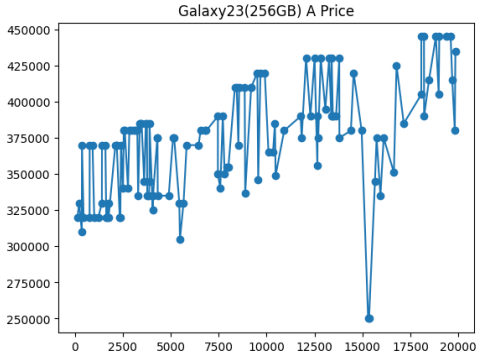

▲ 스마트폰 기종/용량/등급 별 거래 추이 그래프

딥러닝 기반 중고 스마트폰 거래 도움 서비스

03

- 시계열 분석을 통한 중고 스마트폰 미래 가격 예측

시계열 분석 모델 선정

1. 시계열 분석 모델 선정

- 중고 스마트폰 거래는 산발적이며, 기준별 통합 시계열 패턴 학습이 필요해 시계열 기반 모델링을 선택함
- 거래 일자 데이터가 없음 → Prohet 모델 사용 불가
- 다양한 기종, 용량, 등급의 거래 데이터가 혼재 되어 있음 → ARIMA 모델 사용 어려움
- 거래 가격의 추세가 뚜렷하지 않고, 노이즈가 강함 → LSTM 모델 사용 시 성능 낮을 것으로 예상됨

→ TCN(Temporal Convolutional Network) 모델 선택

- 거래 순서로 시계열 분석이 가능
- 하나의 모델에서 기종, 용량, 등급 별 여러 조합 학습 가능
- 노이즈에 대한 민감도가 낮고, 긴 시퀀스 처리도 안정적임
- 데이터가 많지 않아도 안정적으로 학습 가능

데이터 전처리

1. TCN 모델 학습용 데이터셋 생성

- 기종(model), 용량(capacity), 등급(grade) 별로 그룹화하여 개별 시계열로 구성
- 각 시계열에서 일정 길이만큼 슬라이딩 윈도우 방식으로 입력 데이터 생성
  과거 n개 거래 금액 → 미래 1개 거래 금액 예측

2. 범주형 변수 인코딩

- 기종, 용량, 등급 변수를 각각 레이블 인코딩 후 TCN 내 Embedding Layer에서 8차원 벡터로 변환
- 비슷한 조합끼리 유사도 학습 가능, 시계열 정보와 결합 용이

3. 데이터 분할

- 무작위 샘플링이 아닌, 데이터 순서를 유지해 train, validation, test 데이터 분할

딥러닝 기반 중고 스마트폰 거래 도움 서비스

- 시계열 분석을 통한 중고 스마트폰 미래 가격 예측

모델 학습 및 평가

1. TCN 모델 구조

- 2개의 Dilated Convolution Layer로 구성
- Casual padding 적용하여 시계열 순서 보존
- 각 Layer에 20% 비율의 Dropout 적용하여 과적합 방지
- 범주형 변수는 8차원 임베딩 후 시계열 입력과 결합

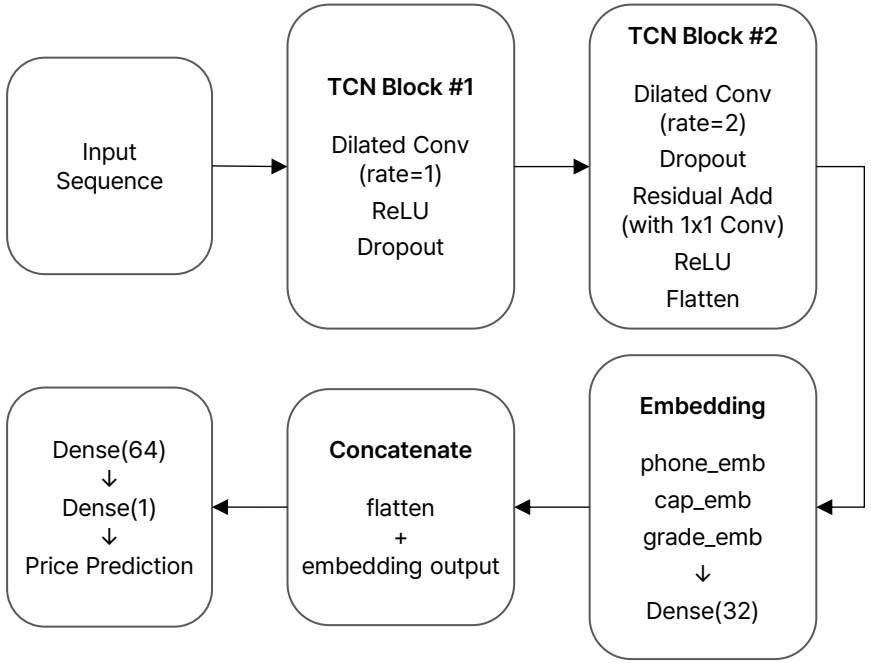

2. 모델 학습

- Batch generator 함수를 정의하여 무작위 샘플링 하되, 시계열 순서를 유지하는 batch 생성
- Early stopping 설정하여 불필요한 과적합 방지
- Epoch=20으로 설정하여 안정적으로 수렴

3. 모델 평가

- MAE: 20670.82, R^2 score: 0.956
- 평균 절대값 오차 약 2만원 수준으로, 실제 거래 변동 폭 대비 안정적인 성능
- 실제 가격과 모델 예측 가격 비교 그래프

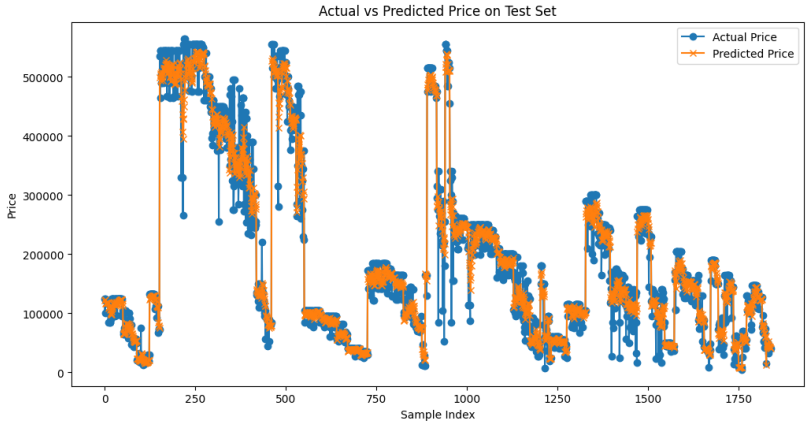

→ 실제 가격과 예측 가격의 그래프에서도 두 값이 유사한 추세를 보여,
모델이 전체적인 가격 변동 패턴을 효과적으로 학습함을 알 수 있음

딥러닝 기반 중고 스마트폰 거래 도움 서비스

- 시계열 분석을 통한 중고 스마트폰 미래 가격 예측

03

가격 예측 그래프 시각화

1. 특정 조합의 가격 예측

- 사용자에게 입력 받은 기종, 용량 정보와 이미지 판별 모델이 분석한 등급을 TCN 모델 입력값으로 변환, 해당 조합의 미래 가격 예측
- 거래수가 부족할 경우 사용자 안내 제공

2. 그래프 시각화

- 과거 20건의 거래 금액과 미래 5건의 예측 가격을 함께 시각화
- 사용자 관점에서 과거와 미래 거래 패턴을 동시에 직관적으로 확인 가능

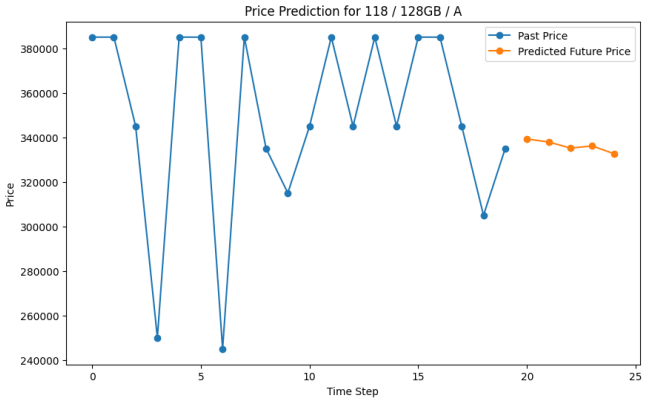

▲ 아이폰 13, 128GB, A등급의 실제 및 예측 가격 그래프

3. 실제 서비스 적용 화면

- 이미지 모델로 판별된 등급과 TCN 모델의 예측 가격이 함께 제공되어 중고 거래를 위한 통합 가이드 제공

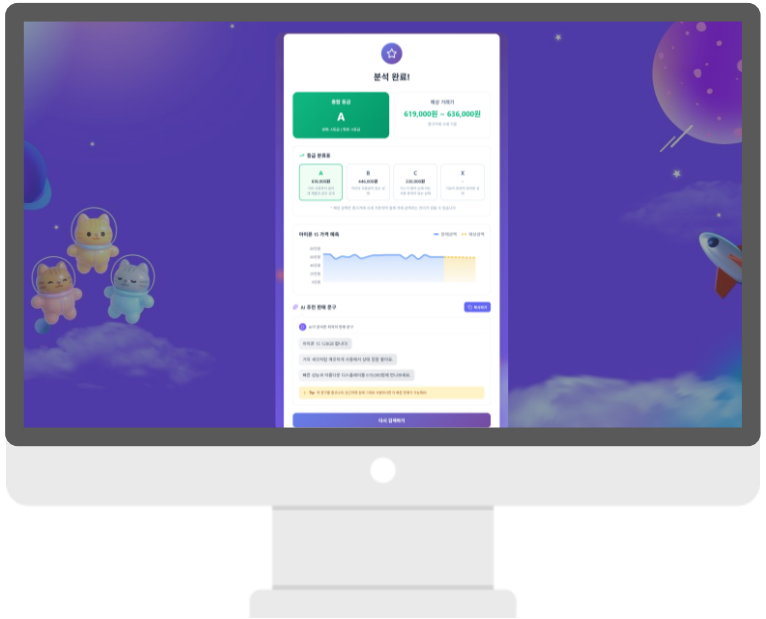

홈페이지 url: http://www.phonezipsa.com/phone

딥러닝 기반 중고 스마트폰 거래 도움 서비스

- 시계열 분석을 통한 중고 스마트폰 미래 가격 예측

03

결론 및 시사점

Summary | 분석 요약

데이터 탐색	특정 조합별 거래 금액 시각화를 통해 노이즈가 강한 거래 패턴 확인
데이터 전처리	슬라이딩 윈도우 기반의 시퀀스 데이터셋 구축
모델링	2개의 Convolution layer로 구성된 TCN 모델 생성, MAE와 R^2 score 기반으로 모델 평가 수행
시각화	사용자가 입력한 스마트폰 정보와 이미지 모델이 판정한 등급 정보를 입력 받아 향후 5건의 거래 가격 예측 및 그래프 제공

Key Finding | 주요 결과

- TCN 모델이 시계열 패턴을 안정적으로 학습, 불규칙한 가격 변동에도 잘 대응
- LSTM 대비 입력 길이 증가에도 성능 저하가 없고 계산 효율이 우수
- test 데이터에서 예측 가격이 실제 가격과 거의 동일하게 움직여 패턴 학습 능력을 확인
- 실사용 서비스에 적용 가능한 수준의 모델 안정성 확보

Implication | 시사점

1. **중고 시장의 불투명성 개선**
   소비자와 판매자 모두 합리적인 거래 기준을 확인할 수 있어 리스크 감소 및 시장 신뢰도 향상
2. **거래 가이드라인 제공**
   향후 가격 움직임(상승/하락)를 제시하여 중고 거래 시점에 대한 의사결정 지원
3. **데이터 확장 가능성**
   거래 일자, 신제품 발표일 및 출시일 등의 외부 변수를 추가 확보할 경우 예측 고도화 가능

TCN 기반 시계열 분석을 통해 기종, 용량, 등급이 혼재된 중고 스마트폰의 가격 변동을 높은 정확도로 예측할 수 있음을 확인했다.
미래 가격 예측과 이미지 등급 판정이 하나의 사용자 플로우로 통합되어 실제 서비스 가능성을 검증했다.

검토해 주셔서 감사합니다.

THANK YOU

K I M - U K Y O U N G

contact

phone : 010 2890 2501 | mail : ukyoung_k@naver.com